UNIVERSIDAD AUTÓNOMA DE BAJA CALIFORNIA

COORDINACIÓN GENERAL DE FORMACIÓN PROFESIONAL

PROGRAMA DE UNIDAD DE APRENDIZAJE

I. DATOS DE IDENTIFICACIÓN

1. Unidad Académica: Facultad de Ciencias, Ensenada

2. Programa Educativo: Licenciatura en Ciencia de Datos

3. Plan de Estudios: 2022-2

4. Nombre de la Unidad de Aprendizaje: Minería de Textos

5. Clave: 41487

6. HC: 01 **HT:** 01 **HL:** 03 **HPC:** 00 **HCL:** 00 **HE:** 01 **CR:** 06

7. Etapa de Formación a la que Pertenece: Terminal

8. Carácter de la Unidad de Aprendizaje: Obligatoria

9. Requisitos para Cursar la Unidad de Aprendizaje: Ninguno

UNIVERSIDAD AUTÓNOMA DE BAJA CALIFORNIA
REGISTRADO
24 FEBRERO 2022
REGISTRADO
COORDINACIÓN GENERAL DE FORMACIÓN PROFESIONAL

Equipo de diseño de PUA
Omar Álvarez Xochihua

Vo. Bo. de subdirector(es) de Unidad(es) Académica(s)
Priscilla Elizabeth Iglesias Vásquez

Fecha: 12 de enero de 2022

II. PROPÓSITO DE LA UNIDAD DE APRENDIZAJE

La unidad de aprendizaje fortalece el aprendizaje de técnicas y herramientas para analizar y generar información nueva proveniente de datos en formato texto, reafirmar los conocimientos de preprocesamiento, almacenamiento y análisis de datos adquiridos en unidades de aprendizaje previas, lo que permite al estudiante desarrollar un proyecto de Minería de Textos desde su etapa de concepto hasta su terminación.

Se ubica en la etapa terminal, es de carácter obligatorio y forma parte del área de conocimiento Minería de Datos.

III. COMPETENCIA GENERAL DE LA UNIDAD DE APRENDIZAJE

Construir modelos de minería de textos, a través de la utilización de las técnicas de acopio, preprocesado e implementación de algoritmos de clasificación y agrupamiento, para su aplicación en la solución de problemáticas de la vida real, con una actitud propositiva, innovadora y de responsabilidad social.

IV. EVIDENCIA(S) DE APRENDIZAJE

Construye un modelo de minería de textos como proyecto final que utilice las técnicas fundamentales de acopio, preprocesado e implementación de algoritmos de clasificación y agrupamiento estudiadas en el curso. Seleccionando un área de aplicación donde de solución a un problema de la vida real o atienda un área de oportunidad identificada. Preferentemente mediante su colaboración en equipo, presenta y reporta los resultados obtenidos tanto de forma oral como escrita.

V. DESARROLLO POR UNIDADES
UNIDAD I. Fundamentos de minería de textos

Competencia:
Analizar los conceptos y aplicaciones de la minería de textos y su vinculación con el procesamiento de lenguaje natural, mediante el estudio de proyectos reales de referencia en el área de estudio, para valorar su importancia, beneficios y retos actuales de la disciplina, con una actitud reflexiva y crítica.

Contenido: **Duración:** 2 horas

1.1 Historia, definiciones y elementos básicos
1.2 Aplicaciones prácticas de minería de textos
1.3 Complejidad y diversidad del lenguaje natural
1.4 Minería de Textos y Procesamiento de Lenguaje Natural
1.5 Tareas principales en Minería de Textos
1.6 Retos actuales

UNIDAD II. Preprocesado y anotado de textos
Competencia: Examinar las características y formas de representación de los datos en formato texto, mediante la revisión de las técnicas y herramientas de preprocesamiento, anotado y almacenamiento y análisis de datos, con el fin de formalizar el contenido y la documentación de un corpus de datos para su futuro procesamiento, con una actitud crítica, propositiva e innovadora.
Contenido: **Duración:** 2 horas 2.1 Características estructurales de los textos 2.2 Características de representatividad y calidad de un corpus: fuente, tamaño de la muestra, etc. 2.3 Adquisición de datos (web crawling y scraping) 2.4 Preprocesado de datos 2.5 Anotación de datos 2.6 Herramientas y librerías para manipulación de textos

UNIDAD III. Representación de textos
Competencia: Examinar los métodos de representación de textos tradicionales y distribuidos, mediante la revisión de las técnicas y herramientas de representación de datos tipo texto utilizando diferentes niveles de granularidad, para representar numéricamente texto no-estructurado y éste pueda ser procesado computacionalmente, con una actitud crítica, propositiva e innovadora.
Contenido: **Duración:** 3 horas 3.1 Modelo de espacio vectorial 3.2 Representación distribuida de palabras 3.3 Representación distribuida de frases o enunciados 3.4 Representación distribuida de sentencias y párrafos 3.5 Representación distribuida de documentos

UNIDAD IV. Algoritmos de clasificación
Competencia: Analizar los principales modelos de clasificación utilizados en la minería de textos, mediante la aplicación de sus algoritmos básicos y la comparación de sus resultados, para la identificación de patrones no triviales de documentos en formato texto que brinden nuevo conocimiento, con una actitud crítica, propositiva e innovadora.
Contenido: **Duración:** 5 horas 4.1 Selección de características 4.2 Algoritmos tradicionales (Naive Bayes, SVM) 4.3 Métodos de aprendizaje profundo (CNN, RNN) 4.4 Evaluación de desempeño

UNIDAD V. Algoritmos de agrupamiento
Competencia: Analizar los principales modelos de agrupación (clustering) utilizados en la minería de textos, mediante la aplicación de sus algoritmos básicos y la comparación de sus resultados, para la identificación de patrones no triviales de documentos en formato texto que brinden nuevo conocimiento, con una actitud crítica, propositiva e innovadora.
Contenido: **Duración:** 4 horas 5.1 Medidas de similaridad en textos 5.2 Algoritmos tradicionales (K-means, Single-Pass, Hierarchical) 5.3 Evaluación de desempeño

VI. ESTRUCTURA DE LAS PRÁCTICAS DE TALLER				
No.	**Nombre de la Práctica**	**Procedimiento**	**Recursos de Apoyo**	**Duración**
UNIDAD I				
1	Análisis de minería de textos.	1. Atiende las orientaciones del docente. 2. Analiza referencias sobre los antecedentes y aplicaciones de minería de textos. 3. Analiza la relación y diferencias entre minería de textos y procesamiento de lenguaje natural. 4. Discute ante grupo los hallazgos. 5. Entrega reporte de revisión bibliográfica realizada y hallazgos.	● Computadora ● Internet	2 horas
UNIDAD II				
2	Anotación y preprocesado de datos	1. Atiende las orientaciones del docente. 2. Compara diferentes técnicas y herramientas para adquisición, preprocesado y anotación de datos. 3. Discute ante grupo los hallazgos. 4. Entrega reporte de revisión bibliográfica realizada y hallazgos.	● Computadora ● Internet	3 horas
UNIDAD III				
3	Representación de textos	1. Atiende las orientaciones del docente. 2. Compara diferentes técnicas y	● Computadora ● Internet	3 horas

		herramientas para representar datos en formato de texto, considerando diferentes niveles de tokenizado: palabras, frases, sentencias y documentos. 3. Discute ante grupo los hallazgos. 4. Entrega reporte de revisión de técnicas realizadas y hallazgos.		
UNIDAD IV				
4	Modelos de clasificación	1. Atiende las orientaciones del docente. 2. Compara diferentes modelos de clasificación de datos en formato de texto, considerando selección de características, algoritmos tradicionales y de aprendizaje profundo. 3. Discute ante grupo los hallazgos. 4. Entrega reporte de revisión de modelos analizados y hallazgos.	● Computadora ● Internet	4 horas
UNIDAD V				
5	Modelos de agrupamiento	1. Atiende las orientaciones del docente. 2. Comparar diferentes modelos de agrupación de datos en formato de texto, considerando algoritmos tradicionales. 3. Discute ante grupo los hallazgos.	● Computadora ● Internet	4 horas

		4. Entrega reporte de revisión de modelos analizados y hallazgos.		

VI. ESTRUCTURA DE LAS PRÁCTICAS DE LABORATORIO				
No.	**Nombre de la Práctica**	**Procedimiento**	**Recursos de Apoyo**	**Duración**
UNIDAD II				
1	Anotación y preprocesado de datos	1. Atiende las orientaciones del docente. 2. Selecciona un conjunto de datos de trabajo. 3. Implementa distintas técnicas para adquisición, preprocesado y anotación de datos. 4. Entrega el conjunto de datos procesado y la documentación de sus características.	● Computadora ● Internet ● Compilador o intérprete de lenguaje de programación. ● Diferentes conjuntos de datos (datasets) en formato texto.	8 horas
UNIDAD III				
2	Representación de textos	1. Atiende las orientaciones del docente. 2. Implementa diferentes técnicas y herramientas para representar datos en formato de texto, considerando diferentes niveles de tokenizado: palabras, frases, sentencias y documentos. 3. Entrega el conjunto de datos procesado y la documentación de sus características.	● Computadora ● Internet ● Compilador o intérprete de lenguaje de programación. ● Diferentes conjuntos de datos (datasets) en formato texto.	12 horas
UNIDAD IV				
3	Modelos de clasificación	1. Atiende las orientaciones del docente. 2. Implementa diferentes modelos de clasificación de datos en formato de texto, considerando selección de características y	● Computadora ● Internet ● Compilador o intérprete de lenguaje de programación. ● Diferentes conjuntos de datos (datasets) en formato texto.	8 horas

		algoritmos tradicionales. 3. Entrega los scripts utilizados y la documentación que describa el desempeño de los modelos implementados.		
4	Modelos de clasificación avanzado	1. Atiende las orientaciones del docente. 2. Implementa diferentes modelos de clasificación de datos en formato de texto, considerando selección de características, algoritmos tradicionales y de aprendizaje profundo. 3. Entrega los scripts utilizados y la documentación que describa el desempeño de los modelos implementados.	● Computadora ● Internet ● Compilador o intérprete de lenguaje de programación. ● Diferentes conjuntos de datos (datasets) en formato texto.	8 horas
UNIDAD V				
5	Modelos de agrupamiento	1. Atiende las orientaciones del docente. 2. Implementa diferentes modelos de agrupación de datos en formato de texto, evaluando diferentes configuraciones de los algoritmos estudiados. 3. Entrega los scripts utilizados y la documentación que describa el desempeño de los modelos implementados.	● Computadora ● Internet ● Compilador o intérprete de lenguaje de programación. ● Diferentes conjuntos de datos (datasets) en formato texto.	12 horas

VII. MÉTODO DE TRABAJO

Encuadre: El primer día de clase el docente debe establecer la forma de trabajo, criterios de evaluación, calidad de los trabajos académicos, derechos y obligaciones docente-alumno.

Estrategia de enseñanza (docente):

- Método de proyectos
- Aprendizaje basado en problemas
- Técnica expositiva
- Debates
- Ejercicios prácticos
- Instrucción guiada

Estrategia de aprendizaje (alumno):

- Investigación documental
- Estudio de caso
- Trabajo en equipo
- Herramientas para seguimiento de trabajo colaborativo
- Exposiciones
- Resúmenes
- Proyecto
- Cuadros comparativos

VIII. CRITERIOS DE EVALUACIÓN

La evaluación será llevada a cabo de forma permanente durante el desarrollo de la unidad de aprendizaje de la siguiente manera:

Criterios de acreditación

- Para tener derecho a examen ordinario y extraordinario, el estudiante debe cumplir con los porcentajes de asistencia que establece el Estatuto Escolar vigente.
- Calificación en escala del 0 al 100, con un mínimo aprobatorio de 60.

Criterios de evaluación

Evaluaciones parciales… 10%
Tareas/prácticas…… 40%
Proyecto final …… 50%
Total …….. 100%

IX. REFERENCIAS	
Básicas	**Complementarias**
Ignatow, G., & Mihalcea, R. (2017). *Text mining*. SAGE Publications, Inc https://www.doi.org/10.4135/9781483399782 Silahtaroglu, G., & Doguc, O. (2019). *Concepts of text mining*: with python and real life exercises. Independently published Zong, C., Xia, R., & Zhang, J. (2021). *Text data mining*, Tsinghua University Press, Beijing, China	Dalianis, H. (2018). *Clinical text mining*: *Secondary use of electronic patient records*. Springer Nature. Ignatow, G., & Mihalcea, R. F. (2017) *An Introduction to Text Mining*: Research Design, Data Collection, and Analysis.SAGE Publications, Inc; Zhang, C., & Han, J., (2019). *Multidimensional Mining of Massive Text Data* (Synthesis Lectures on Data Mining and Knowledge Discovery). Morgan & Claypool Publishers.

X. PERFIL DEL DOCENTE
Licenciatura en Ciencia de datos o área afín; preferentemente con estudios de posgrado y dos años de experiencia de práctica docente, con amplio dominio de los contenidos temáticos, que le permitan proporcionar al estudiante las herramientas, técnicas y habilidades necesarias para esta área de conocimiento. Además, debe ser proactivo, analítico y que fomente el trabajo en equipo.