UNIVERSIDAD AUTÓNOMA DE BAJA CALIFORNIA

COORDINACIÓN GENERAL DE FORMACIÓN PROFESIONAL

PROGRAMA DE UNIDAD DE APRENDIZAJE

I. DATOS DE IDENTIFICACIÓN

1. Unidad Académica: Facultad de Ciencias, Ensenada

2. Programa Educativo: Licenciatura en Ciencia de Datos

3. Plan de Estudios: 2022-2

4. Nombre de la Unidad de Aprendizaje: Procesamiento del Lenguaje Natural

5. Clave: 41493

6. HC: 02 **HT:** 01 **HL:** 02 **HPC:** 00 **HCL:** 00 **HE:** 02 **CR:** 07

7. Etapa de Formación a la que Pertenece: Terminal

8. Carácter de la Unidad de Aprendizaje: Obligatoria

9. Requisitos para Cursar la Unidad de Aprendizaje: Ninguno

UNIVERSIDAD AUTÓNOMA DE BAJA CALIFORNIA
REGISTRADO
24 FEBRERO 2022
REGISTRADO
COORDINACIÓN GENERAL DE FORMACIÓN PROFESIONAL

Equipo de diseño de PUA
Omar Álvarez Xochihua

Vo. Bo. de subdirector(es) de Unidad(es) Académica(s)
Priscilla Elizabeth Iglesias Vásquez

Fecha: 13 de enero de 2022

II. PROPÓSITO DE LA UNIDAD DE APRENDIZAJE

La unidad de aprendizaje fortalece el aprendizaje de los principios del análisis semántico y del conocimiento lingüístico, así como métodos de representación del lenguaje natural, lo que permite al estudiante el uso de las herramientas metodológicas y de procesamiento computacional para el desarrollo de un proyecto de Procesamiento de Lenguaje Natural desde su etapa de concepto hasta su terminación.

Se ubica en la etapa terminal, es de carácter obligatorio, y forma parte del área de conocimiento Ciencia de Datos.

III. COMPETENCIA GENERAL DE LA UNIDAD DE APRENDIZAJE

Construir modelos de lenguaje natural, a través de la utilización de las técnicas y algoritmos empleados en el aprendizaje automático, para su aplicación en la solución de problemáticas que atienden el entendimiento y procesamiento de lenguaje natural, con una actitud propositiva, innovadora y de responsabilidad social.

IV. EVIDENCIA(S) DE APRENDIZAJE

Construye un modelo de lenguaje natural como proyecto final que utilice las técnicas fundamentales de acopio, preprocesado e implementación de algoritmos estudiados en el curso. Seleccionando un área de aplicación donde de solución a un problema de la vida real, tales como traducción automática, sistemas de comprensión, elaboración de resúmenes, análisis de contexto, con una actitud propositiva. Preferentemente mediante su colaboración en equipo, presenta y reporta los resultados obtenidos tanto de forma oral como escrita.

V. DESARROLLO POR UNIDADES
UNIDAD I. Fundamentos de Procesamiento de Lenguaje Natural

Competencia:
Analizar los conceptos y aplicaciones de lingüística computacional y su relación con el procesamiento de lenguaje natural, mediante el estudio de los enfoques utilizados para el procesado del lenguaje humano, con la finalidad de interpretar la importancia, beneficios y variedades de aplicaciones manipulando lenguaje natural, con una actitud sistémica y crítica.

Contenido: **Duración:** 2 horas

1.1. Lingüística computacional
1.2. Procesamiento de lenguaje natural (PLN)
1.3. Áreas de estudio de PLN en el mundo real
    1.3.1. Análisis de sentimiento
    1.3.2. Minería de opinión
    1.3.3. Análisis de contexto
    1.3.4. Otros
1.4. Enfoques de PLN
    1.4.1. PLN basado en heurísticas
    1.4.2. PLN basado en aprendizaje automático
    1.4.3. PLN basado en aprendizaje profundo
1.5. Vinculación con Minería de Textos
1.6. Retos actuales

UNIDAD II. Método para PLN
Competencia: Analizar las fases del proceso de Procesamiento de Lenguaje Natural, mediante el estudio de las tareas realizadas en cada una de sus etapas, para interpretar la importancia y productos esperados en cada fase, con una actitud metódica y crítica.
Contenido: **Duración:** 2 horas 2.1. Adquisición de datos 2.2. Extracción y limpieza de textos (ortografía, énfasis, atípicos) 2.3. Preprocesado (tokenizado, normalización) 2.4. Selección de características (textuales y no-textuales) 2.5. Modelado 2.6. Evaluación 2.7. Implementación y monitoreo de modelos

UNIDAD III. Representación de texto
Competencia: Analizar los métodos de representación de textos tradicionales en Procesamiento de Lenguaje Natural, mediante la revisión de las técnicas y herramientas convencionales y actualizadas de representación de este tipo de datos, para representar texto no-estructurado y pueda ser procesado computacionalmente, con una actitud crítica, propositiva e innovadora.
Contenido: **Duración:** 6 horas 3.1. Modelo de espacio vectorial 3.2. Enfoques de vectorización 3.2.1. One-Hot encoding 3.2.2. Bag of Words 3.2.3. N-Grams 3.2.4. TF-IDF 3.2.5. Word embeddings 3.3. Representación de características adicionales 3.3.1. Representación de textos universal (BERT) 3.3.2. Visualización de incrustaciones 3.3.3. Representaciones propietarias

UNIDAD IV. Análisis semántico
Competencia: Analizar métodos de interpretación semántica, mediante la implementación de técnicas de análisis semántico latente, para identificar patrones entre palabras pertenecientes a documentos de un corpus asumiendo la similitud de significado de términos que se utilizan en un determinado contexto, con una actitud sistemática, reflexiva y crítica.
Contenido: **Duración:** 6 horas 4.1. Análisis semántico latente 4.2. Descomposición de valores singulares 4.2.1. Vectores singulares U-left, VT-right 4.2.2. Matriz de DVS 4.3. Análisis de componentes principales 4.4. Distancia y similaridad

UNIDAD V. Modelado

Competencia:
Analizar los principales modelos de clasificación y agrupamiento utilizados en el Procesamiento de Lenguaje Natural, mediante la aplicación de sus algoritmos básicos y la comparación de sus resultados, para la identificación de patrones no triviales de documentos en formato texto que brinden nuevo conocimiento, con una actitud crítica, propositiva e innovadora.

Contenido: **Duración:** 6 horas

5.1. Algoritmos de clasificación
5.2. Algoritmos de agrupamiento
5.3. Algoritmos de aprendizaje profundo (RNN, CNN, LSTM)
5.4. Interpretación de modelos de clasificación y agrupamiento

UNIDAD VI. Aplicaciones de PLN

Competencia:
Ejecutar el proceso de Procesamiento de Lenguaje Natural, mediante la aplicación de las técnicas de adquisición de datos, extracción y limpieza de textos, preprocesado, selección de características y modelado, para implementar un proyecto que requiera el procesado de lenguaje en diferentes entornos de aplicación, con una actitud de trabajo conjunto y equitativo.

Contenido: **Duración:** 10 horas

6.1. Redes sociales
- 6.1.1. Áreas de interés (memes, noticias falsas, análisis de opinión)
- 6.1.2. Modelado de tópicos
- 6.1.3. Análisis de tópicos de tendencia
- 6.1.4. Preprocesado y representación de texto

6.2. Asistentes inteligentes
- 6.2.1. Preguntas frecuentes
- 6.2.2. Diálogos orientado a objetivos
- 6.2.3. Clasificaciones Diálogo-Acción
- 6.2.4. Generación de respuesta

6.3. Comercio electrónico
- 6.3.1. Áreas de interés (anotaciones, búsqueda de productos, recomendaciones)
- 6.3.2. Extracción de atributos
- 6.3.3. Categorización de productos y taxonomía
- 6.3.4. Sistema de recomendación
- 6.3.5. Análisis de opinión y sentimiento

6.4. Análisis de área de estudio alterna

VI. ESTRUCTURA DE LAS PRÁCTICAS DE TALLER				
No.	**Nombre de la Práctica**	**Procedimiento**	**Recursos de Apoyo**	**Duración**
UNIDAD I				
1	Análisis de Procesamiento de Lenguaje Natural	1. Atiende las orientaciones del docente. 2. Analiza y compara áreas de estudio de PLN. 3. Relaciona aplicaciones de PLN en diferentes dominios para proponer una solución a una problemática o área de oportunidad. 4. Discusión en grupo de los hallazgos. 5. Entrega reporte de revisión bibliográfica realizada y hallazgos.	• Computadora • Internet	2 horas
2	Análisis de enfoques de aplicaciones de Procesamiento de Lenguaje Natural	1. Atiende las orientaciones del docente. 2. Analiza y compara áreas de enfoques de implementación de PLN. 3. Relaciona los enfoques estudiados con posibles áreas de aplicación. 4. Discusión en grupo de los hallazgos. 5. Entrega reporte de revisión bibliográfica realizada y hallazgos.	• Computadora • Internet	2 horas
UNIDAD II				
3	Fases para el Procesamiento de Lenguaje Natural	1. Atiende las orientaciones del docente. 2. Analiza las actividades de cada fase de implementación de	• Computadora • Internet	2 horas

		PLN, e identifica la dependencia entre ellas. 3. Relaciona las particularidades del procesado del lenguaje natural para transformarlo y procesarlo en lenguaje formal. 4. Discusión en grupo sobre los hallazgos. Entrega reporte de revisión bibliográfica realizada y hallazgos.		
UNIDAD III				
4	Representaciones de texto convencionales	1. Atiende las orientaciones del docente. 2. Compara diferentes técnicas y herramientas tradicionalmente utilizadas en la representación de texto, identificando sus usos potenciales, ventajas y desventajas. 3. Discute ante grupo los hallazgos. 4. Entrega reporte de técnicas analizadas, incluyendo los hallazgos.	• Computadora • Internet	3 horas
5	Representaciones de texto más recientes	1. Atiende las orientaciones del docente. 2. Compara diferentes técnicas y herramientas de vanguardia utilizadas en la representación de texto identificando sus usos potenciales, ventajas y desventajas. 3. Discute ante grupo los hallazgos. 4. Entrega reporte de técnicas analizadas, incluyendo los	• Computadora • Internet	3 horas

		hallazgos.		
UNIDAD VI				
6	Implementaciones de usuario final usando Procesamiento de Lenguaje Natural	1. Atiende las orientaciones del docente. 2. Analiza las características de las fuentes de datos y el formato de los mismos, provenientes de diversos dominios de aplicación. 3. Entrega propuesta de una aplicación de usuario final como proyecto de clase.	• Computadora • Internet	4 horas

VI. ESTRUCTURA DE LAS PRÁCTICAS DE LABORATORIO				
No.	**Nombre de la Práctica**	**Procedimiento**	**Recursos de Apoyo**	**Duración**
UNIDAD III				
1	Representaciones de texto convencionales	1. Atiende las orientaciones del docente. 2. Implementa y evalúa implicaciones computacionales de las diferentes técnicas y herramientas tradicionalmente utilizadas en la representación de texto. 3. Entrega el conjunto de datos procesado mediante diferentes técnicas de representación y la documentación de sus características.	• Computadora • Internet • Compilador o intérprete de lenguaje de programación. • Diferentes conjuntos de datos (datasets) en formato texto.	3 horas
2	Representaciones de texto más recientes	1. Atiende las orientaciones del docente. 2. Implementa y evalúa implicaciones computacionales de las diferentes técnicas y herramientas de vanguardia utilizadas en la representación de texto. 3. Entrega el conjunto de datos procesado mediante diferentes técnicas de representación y la documentación de sus características.	• Computadora • Internet • Compilador o intérprete de lenguaje de programación. • Diferentes conjuntos de datos (datasets) en formato texto.	3 horas
UNIDAD IV				
3	Análisis semántico	1. Atiende las orientaciones del docente. 2. Implementa y evalúa implicaciones computacionales de las diferentes técnicas y herramientas de	• Computadora • Internet • Compilador o intérprete de lenguaje de programación. • Diferentes conjuntos de datos	3 horas

		vanguardia utilizadas en la interpretación semántica de texto. 3. Entrega el conjunto de datos procesado mediante diferentes técnicas de representación semántica y la documentación de sus características.	(datasets) en formato texto.	
UNIDAD V				
4	Modelado de Procesamiento de Lenguaje Natural	1. Atiende las orientaciones del docente. 2. Implementa diferentes modelos de clasificación y agrupación de datos en formato de texto, considerando selección de características, algoritmos tradicionales y de aprendizaje profundo. 3. Entrega los scripts utilizados y la documentación que describa el desempeño de los modelos implementados.	• Computadora • Internet • Compilador o intérprete de lenguaje de programación. • Diferentes conjuntos de datos (datasets) en formato texto.	5 horas
UNIDAD VI				
5	Selección de dominio de aplicación de Procesamiento de Lenguaje Natural	1. Atiende las orientaciones del docente. 2. Selecciona un dominio de aplicación y define la implementación de una aplicación de usuario final. 3. Entrega documento final (protocolo) de proyecto.	• Computadora • Internet • Compilador o intérprete de lenguaje de programación. • Diferentes conjuntos de datos (datasets) en formato texto.	3 horas
6	Implementación de aplicación de usuario final.	1. Atiende las orientaciones del docente. 2. Analizar, diseñar e implementar una aplicación de Procesamiento de Lenguaje Natural en el dominio seleccionado. 3. Semanalmente presentará	• Computadora • Internet • Compilador o intérprete de lenguaje de programación. • Diferentes conjuntos de datos (datasets) en formato texto.	15 horas

		documento de avances del proyecto. 4. Presenta la funcionalidad del proyecto final ante el grupo.		

VII. MÉTODO DE TRABAJO

Encuadre: El primer día de clase el docente debe establecer la forma de trabajo, criterios de evaluación, calidad de los trabajos académicos, derechos y obligaciones docente-alumno.

Estrategia de enseñanza (docente):

- Método de proyectos
- Aprendizaje basado en problemas
- Técnica expositiva
- Debates
- Ejercicios prácticos
- Instrucción guiada

Estrategia de aprendizaje (alumno):

- Investigación documental
- Estudio de caso
- Trabajo en equipo
- Herramientas para seguimiento de trabajo colaborativo
- Exposiciones
- Resúmenes
- Proyecto
- Cuadros comparativos

VIII. CRITERIOS DE EVALUACIÓN

La evaluación será llevada a cabo de forma permanente durante el desarrollo de la unidad de aprendizaje de la siguiente manera:

Criterios de acreditación

- Para tener derecho a examen ordinario y extraordinario, el estudiante debe cumplir con los porcentajes de asistencia que establece el Estatuto Escolar vigente.
- Calificación en escala del 0 al 100, con un mínimo aprobatorio de 60.

Criterios de evaluación

-Evaluaciones parciales… 10%
-Tareas/prácticas……40%
-Proyecto final……. 50%
Total……..…….100%

IX. REFERENCIAS	
Básicas	**Complementarias**
Jurafsky, D. & Martin, J. H. (2020). *Speech and Language Processing*: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition (2nd ed.). Prentice Hall. Vajjala, S., Majumder, B., Gupta, A. & Surana, H. (2020). *Practical Natural Language Processing*. O'Reilly Media, Inc.	Lane, H., Hapke, H. & Howard, C. (2019). *Natural Language Processing in Action*: Understanding, analyzing, and generating text with Python. Manning Rubio, R., & Bernal, J. (2016). *Introducción a la Lingüística Computacional*. Ediciones de la U. [clásica].

X. PERFIL DEL DOCENTE
Licenciatura en Ciencia de datos o área afín; preferentemente con estudios de posgrado y dos años de experiencia de práctica docente, con amplio dominio de los contenidos temáticos, que le permitan proporcionar al estudiante las herramientas, técnicas y habilidades necesarias para esta área de conocimiento.